


Trabajo Semana 3

Julian Andrés Cabrera Murcia

Institución Universitaria Corhuila
Ciencia de Datos
Jesús Ariel González Bonilla

28/08/2026

1. Dibuja (diagrama o ASCII) la arquitectura: fuentes → ingesta → almacenamiento → procesamiento → análisis/BI



2. Justifica: ¿data lake o warehouse? ¿batch o streaming?

¿Data Lake o Data Warehouse?

Para la arquitectura propuesta se selecciona un Data Lake como solución de almacenamiento principal. Un Data Lake permite almacenar grandes volúmenes de datos en su formato original, ya sean datos estructurados, semiestructurados o no estructurados. Esta característica resulta especialmente útil en proyectos de Ciencia de Datos, donde la información puede provenir de múltiples fuentes como sistemas ERP, CRM, sensores IoT, redes sociales y archivos externos.

Además, el Data Lake ofrece una mayor flexibilidad para futuros análisis y modelos de Machine Learning, ya que conserva los datos sin necesidad de transformarlos previamente. También presenta una alta escalabilidad y menores costos de almacenamiento cuando se trabaja con grandes cantidades de información.

Por otro lado, un Data Warehouse está orientado principalmente a datos estructurados y requiere procesos de transformación previos antes de almacenar la información. Aunque es una excelente alternativa para la generación de reportes empresariales, su rigidez limita el tratamiento de datos heterogéneos.

¿Batch o Streaming?

Para el procesamiento de la información se selecciona el enfoque Batch. Este modelo consiste en procesar conjuntos de datos acumulados durante un período determinado, por ejemplo diariamente, semanalmente o mensualmente.

La elección se debe a que la arquitectura propuesta está enfocada en la generación de informes, indicadores de gestión y análisis históricos, actividades que no requieren procesamiento inmediato. El modelo Batch permite optimizar recursos computacionales, reducir costos operativos y simplificar la administración del sistema.

En contraste, el procesamiento Streaming está diseñado para analizar datos en tiempo real y es más adecuado en escenarios como monitoreo de sensores industriales, seguimiento de transacciones financieras o detección de fraudes, donde las decisiones deben tomarse de manera instantánea.

3. Nombra una herramienta candidata por etapa (ingesta, procesamiento, BI) y por qué.

Ingesta: Apache NiFi

Apache NiFi se utiliza para recopilar e integrar datos provenientes de diferentes fuentes, como bases de datos, archivos y aplicaciones. Su principal ventaja es la automatización de los flujos de datos y la facilidad para gestionar la información de manera eficiente.

Procesamiento: Apache Spark

Apache Spark permite procesar grandes volúmenes de datos de forma rápida y eficiente. Se utiliza para realizar tareas de limpieza, transformación y análisis de los datos antes de que sean utilizados para la toma de decisiones.

BI (Business Intelligence): Microsoft Power BI

Power BI es una herramienta de visualización que transforma los datos procesados en gráficos, dashboards e informes interactivos. Esto facilita el análisis de información y el seguimiento de indicadores clave para la empresa.